

12.HAFTA

# YAPAY SİNİR AĞLARI

SAMSUN ÜNİVERSİTESİ



DR.ÖĞR.ÜYESİ ALPER TALHA KARADENİZ

# Transfer Learning (Önceden Eğitilmiş Modeller)

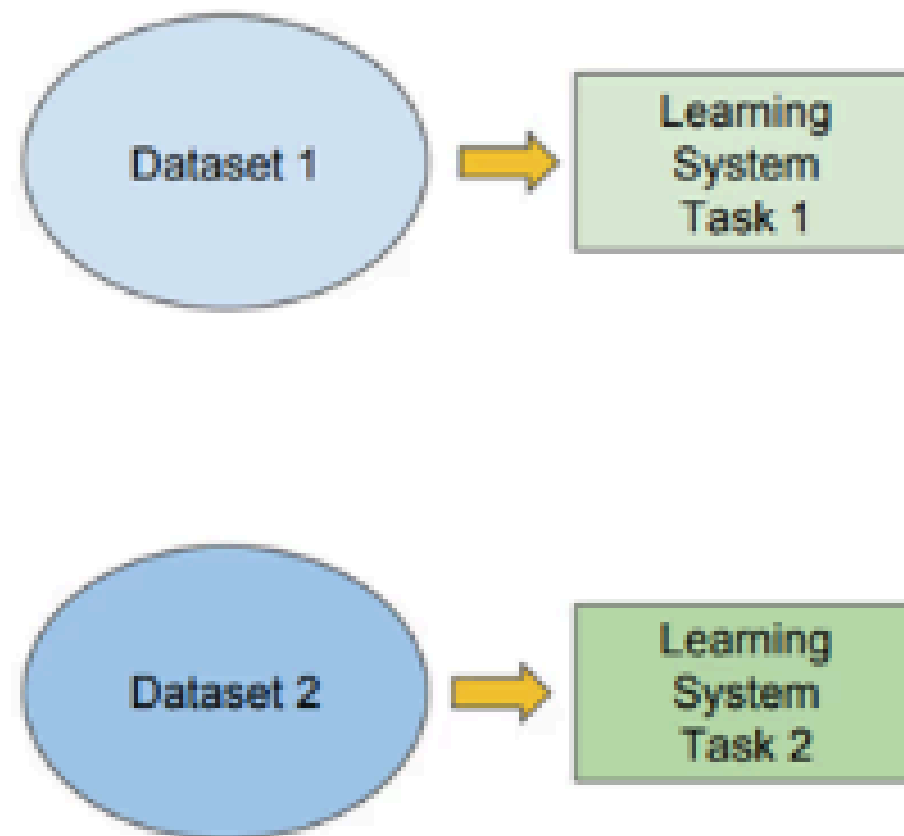
Transfer learning, makine öğrenmesi ve derin öğrenmede önceden eğitilmiş bir modelin farklı ama ilişkili bir problemde tekrar kullanılmasıdır. Normalde sıfırdan bir model eğitmek için büyük miktarda veri, uzun süreli eğitim ve yüksek işlem gücü gerekir. Transfer learning sayesinde, daha önce büyük veri setlerinde eğitilmiş bir modelin öğrendiği bilgileri yeniden kullanarak daha az veri, daha kısa süre ve daha az hesaplama maliyetiyle yeni bir problem çözülebilir.

# Traditional ML

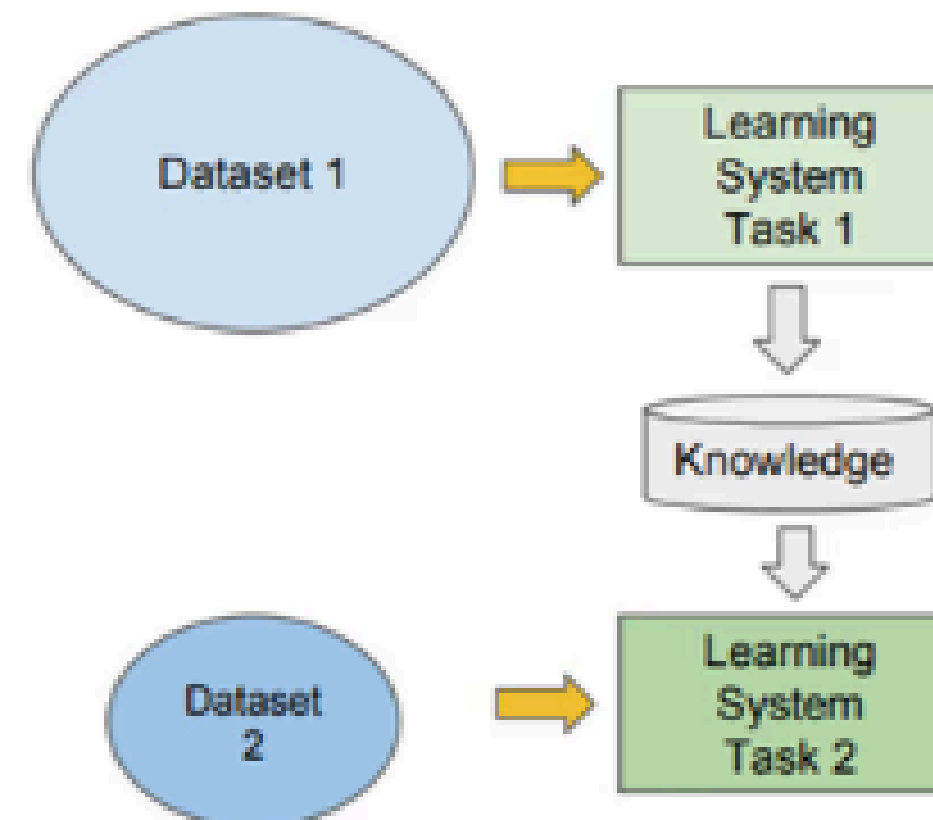
vs

# Transfer Learning

- Isolated, single task learning:
  - Knowledge is not retained or accumulated. Learning is performed w.o. considering past learned knowledge in other tasks



- Learning of a new tasks relies on the previous learned tasks:
  - Learning process can be faster, more accurate and/or need less training data



Bir model büyük ve kapsamlı bir veri seti (örneğin ImageNet, milyonlarca resim içerir) üzerinde eğitildiğinde:

- Temel özellikleri öğrenir (kenarlar, renk geçişleri, şekiller, dokular gibi).
- Bu temel özellikler birçok farklı problemde ortak olarak işe yarar.

Transfer learning'de, modelin bu önceden öğrenilmiş bilgileri yeni bir görev için başlangıç noktası olarak kullanılır.

# Transfer Learning'in Kullanım Yöntemleri

## a) Feature Extraction (Özellik Çıkarımı)

- Önceden eğitilmiş modelin erken katmanları sabit tutulur (dondurulur).
- Bu katmanlar, görselin genel özelliklerini çıkarır.
- Son katman(lar) kaldırılır ve yerine yeni görev için özelleştirilmiş katman(lar) eklenir.
- Sadece eklenen katman(lar) yeniden eğitilir.

Örnek: ImageNet üzerinde eğitilmiş bir CNN'den alınan özelliklerle bir kedi–köpek sınıflandırma modeli eğitmek.

## b) Fine-Tuning (İnce Ayar)

- Önceden eğitilmiş modelin bazı katmanları tekrar eğitilir.
- Özellikle üst katmanlar (probleme özgü özellikleri öğrenen katmanlar) güncellenir.
- Böylece model hem genel özellikleri hem de probleme özel bilgileri öğrenir.

Örnek: Tıp alanındaki akciğer röntgenlerinden hastalık tespiti için ImageNet'te eğitilmiş CNN'in üst katmanlarını yeniden eğitmek.

## Transfer Learning'in Avantajları

- **Az veriyle eğitim:** Büyük veri setine ihtiyaç duyulmaz.
- **Hızlı eğitim:** Eğitim süresi büyük ölçüde kısalır.
- **Yüksek doğruluk:** Önceden öğrenilmiş bilgi, modelin doğruluğunu artırır.
- **Hesaplama maliyeti düşük:** Daha az donanım gücü gerekir.

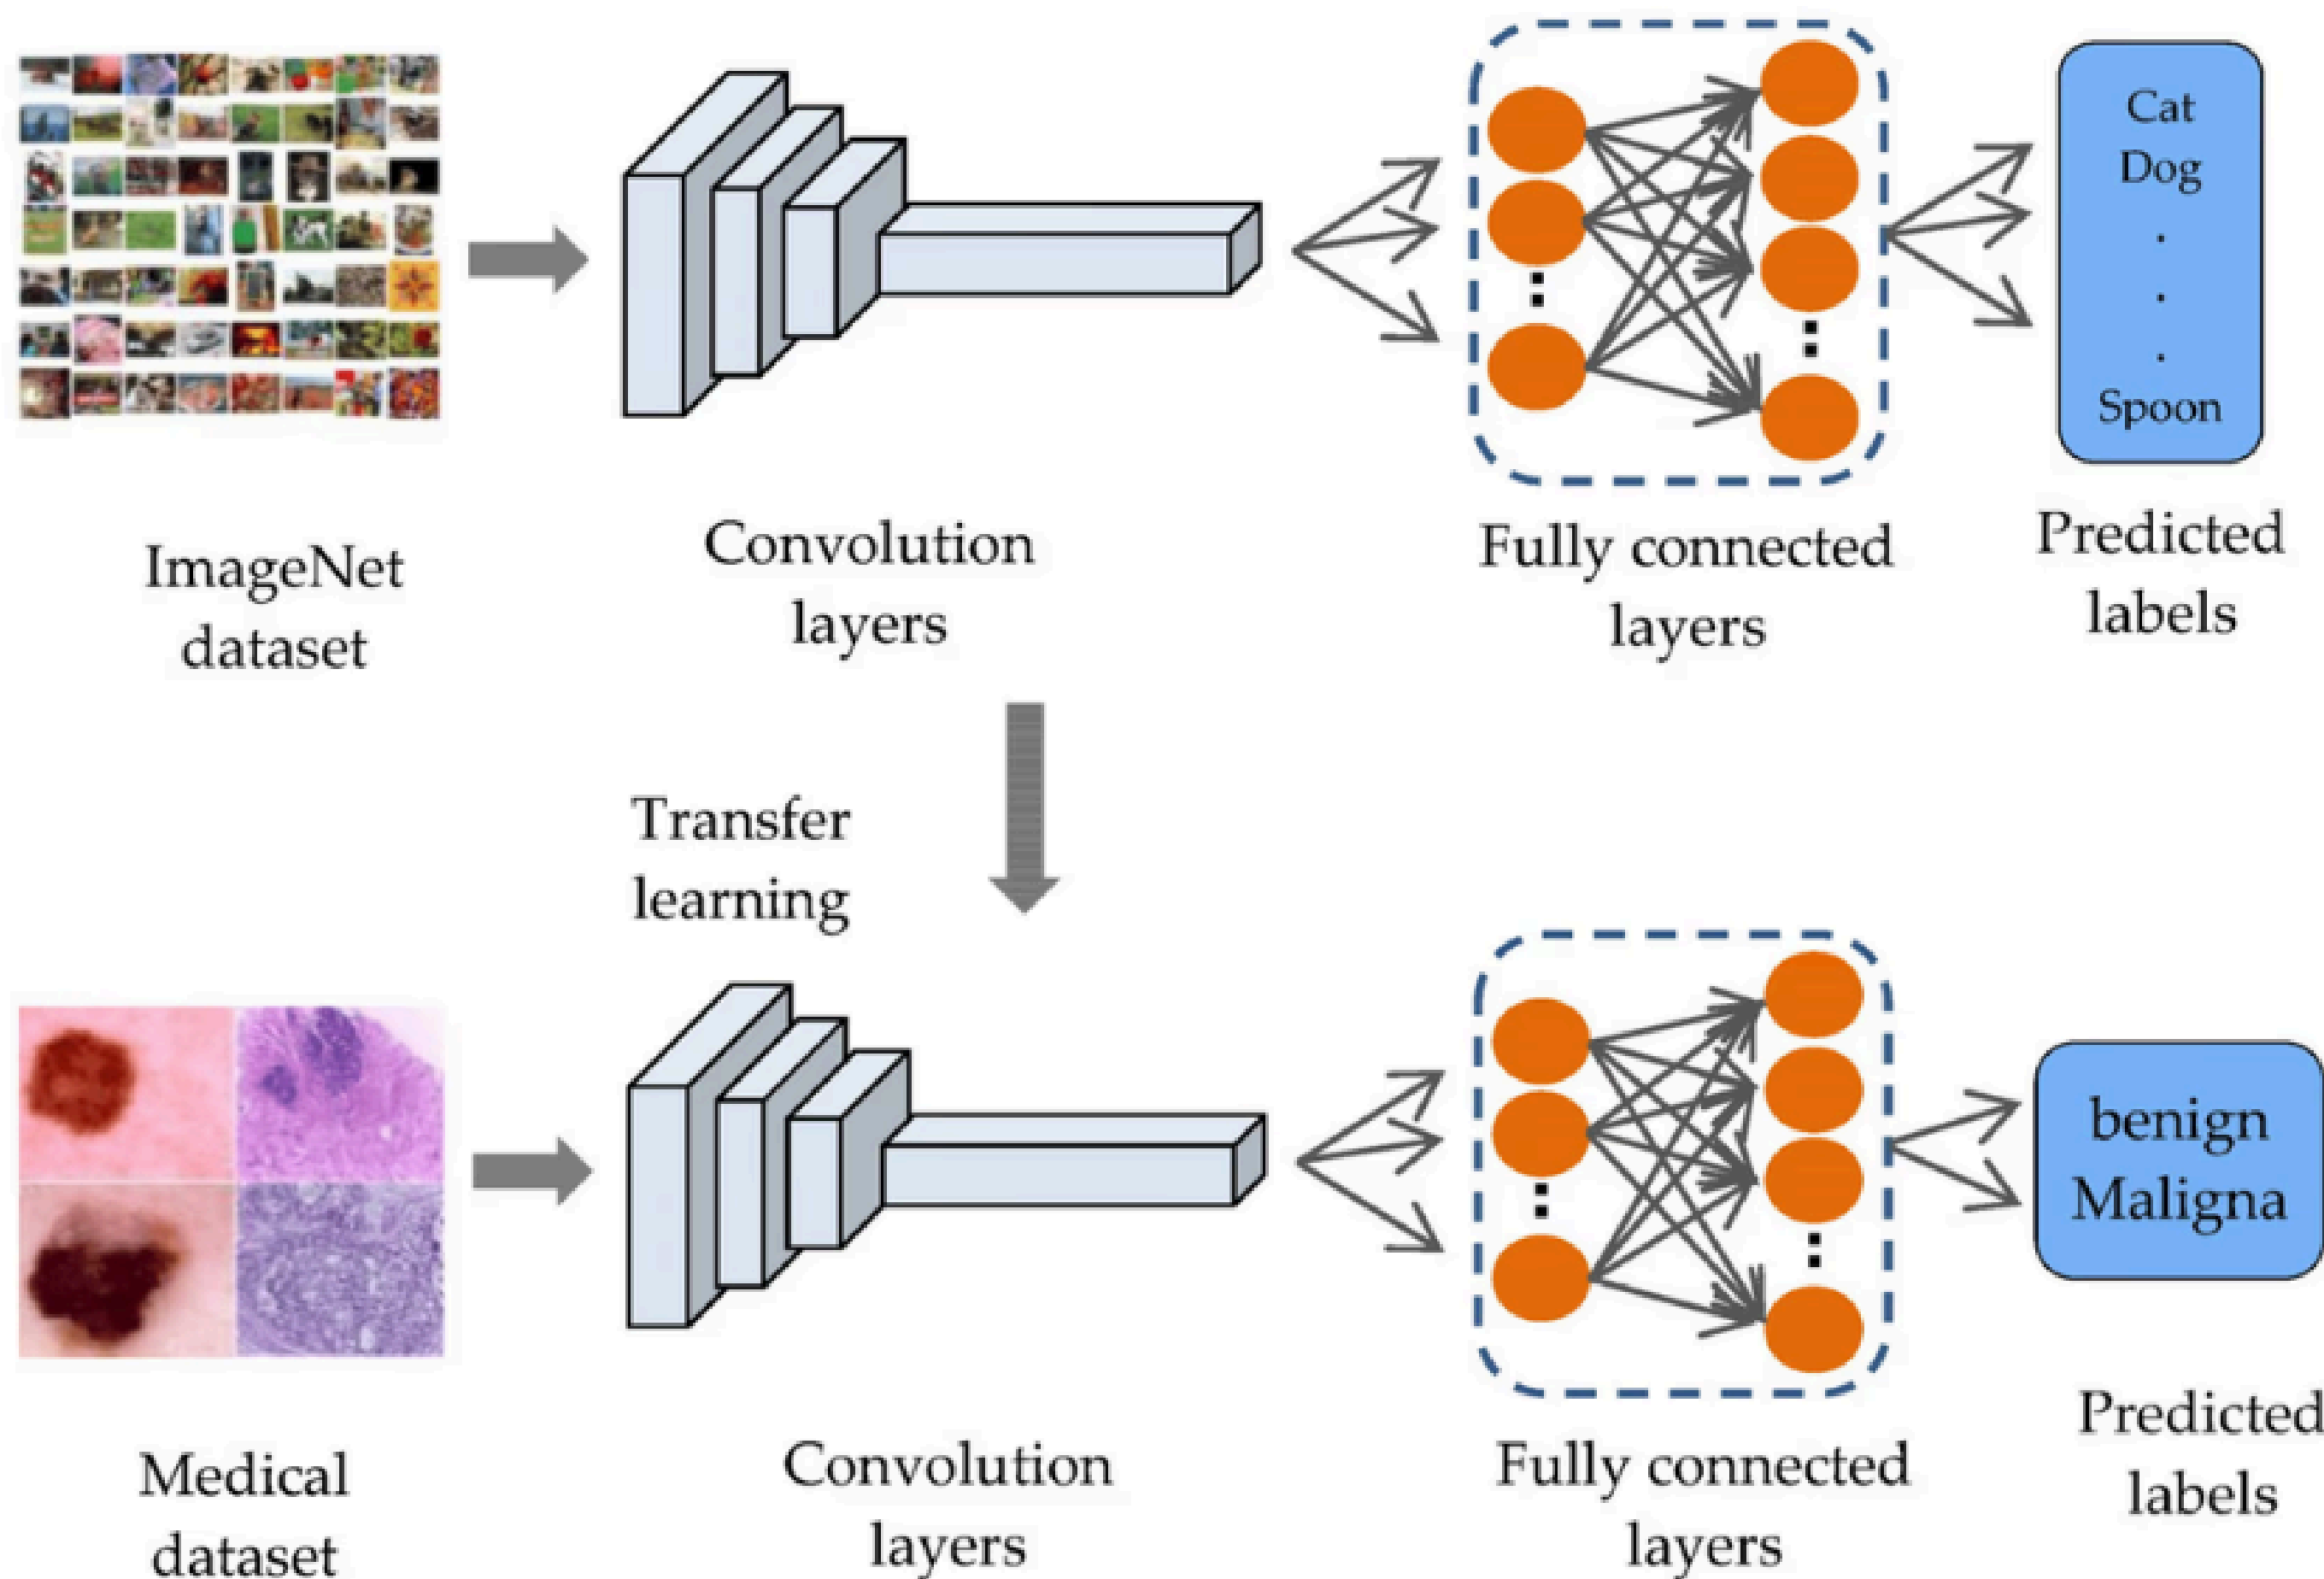
# Transfer Learning'in Kullanım Alanları

- **Bilgisayarlı Görü (Computer Vision):**  
Görüntü sınıflandırma, nesne tespiti, yüz tanıma.
- **Doğal Dil İşleme (NLP):**  
BERT, GPT gibi önceden eğitilmiş dil modelleri; metin sınıflandırma, duygu analizi, makine çevirisi.
- **Konuşma Tanıma:**  
Ses verilerinde önceden eğitilmiş modellerden faydalanma.
- **Sağlık:**  
MRI, röntgen ve CT görüntülerinden hastalık tespiti.



# Popüler Önceden Eğitilmiş Modeller

- Bilgisayarlı Görü için:
  - VGG16, VGG19
  - ResNet
  - Inception
  - MobileNet
  - EfficientNet
- Doğal Dil İşleme için:
  - Word2Vec, GloVe
  - BERT
  - GPT serisi
  - RoBERTa, XLNet




# **AutoML ve Neural Architecture Search (NAS)**

## **AutoML (Automated Machine Learning)**

Automated Machine Learning (AutoML), makine öğrenmesi modellerinin geliştirilme sürecinde insan müdahalesini en aza indirerek; veri ön işleme, model seçimi, hiperparametre optimizasyonu ve değerlendirme adımlarını otomatikleştiren bir yaklaşımdır.

## Traditional Machine Learning Workflow



## AutoML Workflow



# Amaçları

- Makine öğrenmesi bilgi ve deneyimi sınırlı olan kullanıcıların da güçlü modeller geliştirmesini sağlamak.
- Model geliştirme süresini ve maliyetini azaltmak.
- İnsan uzmanların deneme-yanılma yoluyla uzun sürede bulabileceği en iyi modelleri daha kısa sürede keşfetmek.

# AutoML Süreci

## 1. Veri Ön İşleme

- Eksik verilerin doldurulması
- Normalizasyon ve standartlaştırma
- Özellik seçimi ve özellik çıkarımı

## 2. Model Seçimi

- Karar ağaçları, destek vektör makineleri, derin öğrenme modelleri gibi aday algoritmalar arasından seçim yapılır.

### 3. Hiperparametre Optimizasyonu

- Grid Search, Random Search, Bayesian Optimization gibi yöntemlerle modelin en uygun hiperparametreleri bulunur.

### 4. Model Değerlendirme ve Seçim

- Doğruluk (Accuracy), F1-Score, ROC-AUC gibi metrikler kullanılarak modeller karşılaştırılır.
- En iyi performansı gösteren model seçilir.

## Avantajları

- Zaman ve iş gücü tasarrufu sağlar.
- Daha geniş kullanıcı kitlesine makine öğrenmesini erişilebilir kılar.
- Karmaşık hiperparametre ayarlamalarında insan hatasını en aza indirir.





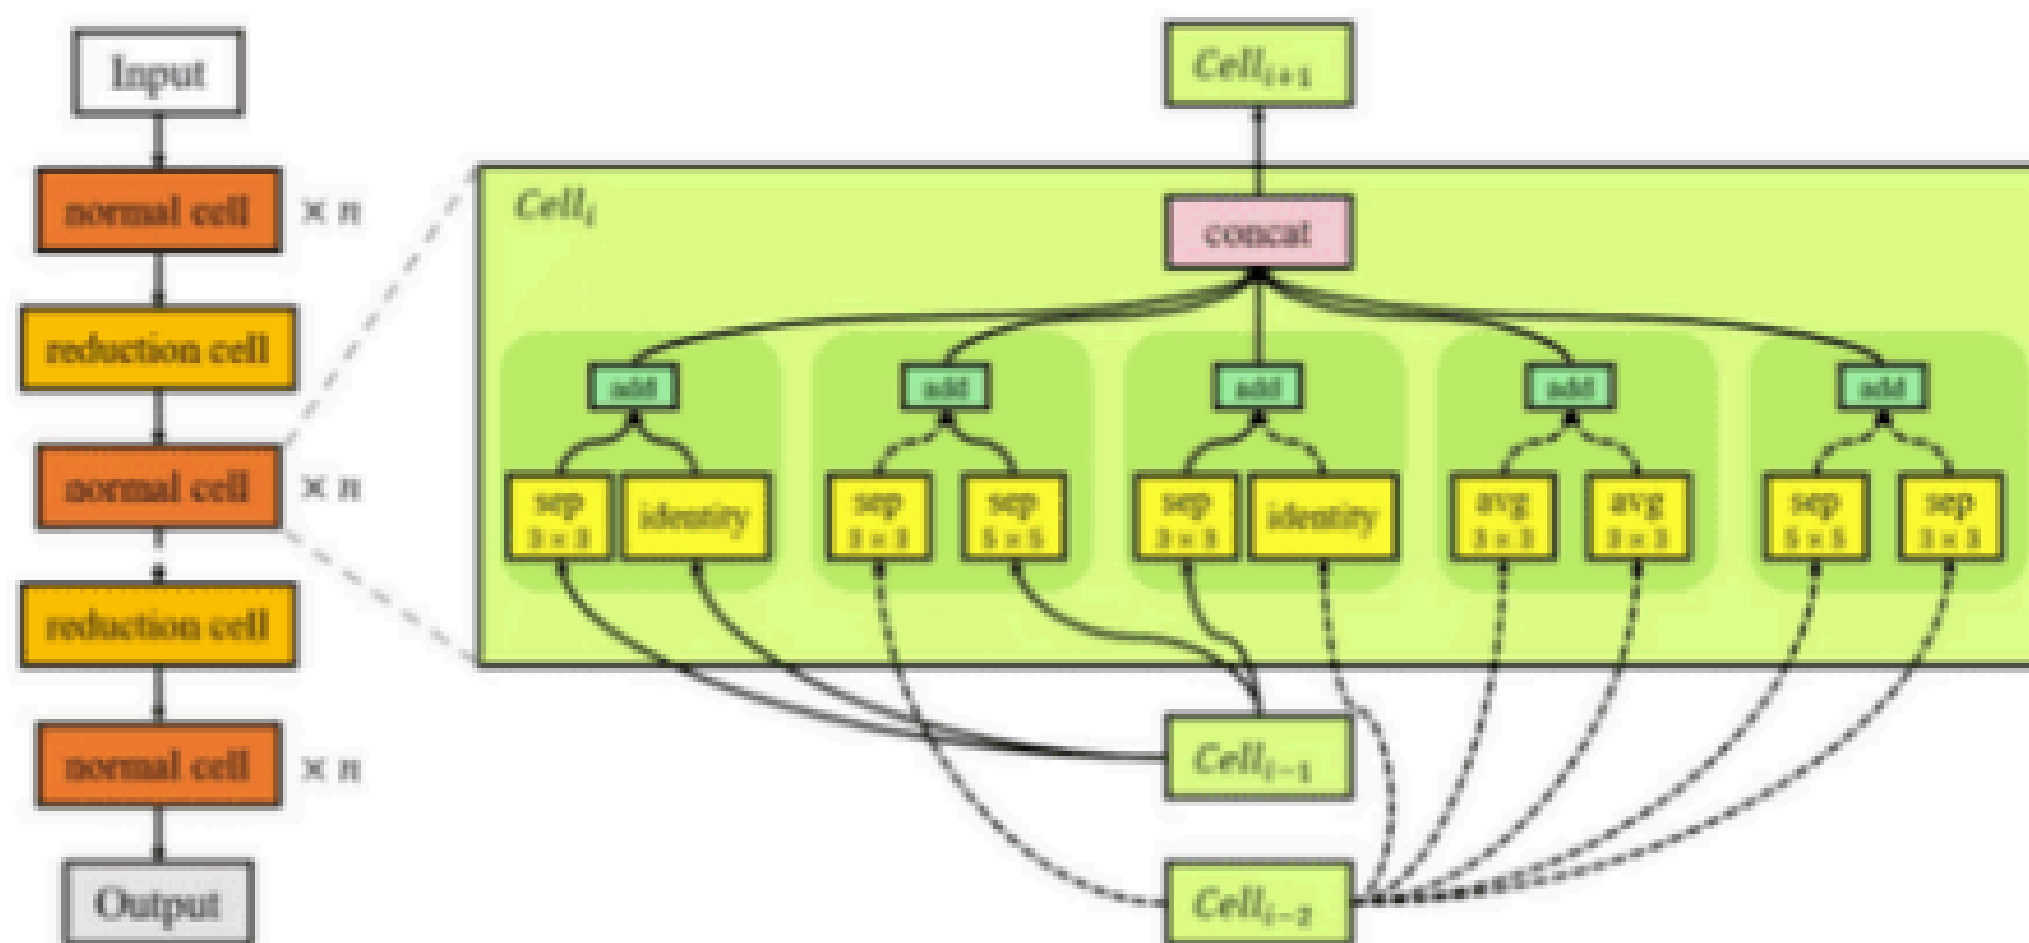
# Neural Architecture Search (NAS)

Neural Architecture Search (NAS), derin sinir ağlarının mimarisini otomatik olarak tasarlamak için kullanılan bir AutoML yöntemidir. Yani NAS, belirli bir problem için en uygun yapay sinir ağı mimarisini keşfetmeyi amaçlar.

## Çalışma Prensipleri

- NAS, bir arama uzayı (search space) tanımlar. Bu uzayda farklı katman türleri, bağlantılar, filtre boyutları ve aktivasyon fonksiyonları gibi mimari bileşenler bulunur.
- Bir arama stratejisi (search strategy) kullanılarak bu uzayda gezilir.
- Elde edilen mimariler performans tahmini (performance estimation) ile değerlendirilir.

# Neural Architecture Search



# NAS Bileşenleri

## 1. Arama Uzayı (Search Space)

- Denenecek olası ağ mimarilerini içerir.
- Örnek: Evrişimli katman, LSTM, GRU, tam bağlantılı katman kombinasyonları.

## 2. Arama Stratejisi (Search Strategy)

- Rastgele arama
- Takviye öğrenmesi (Reinforcement Learning)
- Evrimsel algoritmalar
- Gradyan tabanlı yöntemler

### 3. Performans Tahmini (Performance Estimation)

- Aday mimarilerin hızlıca test edilmesi için kullanılan yöntemlerdir.
- Tüm ağıın baştan sona eğitilmesi yerine; kısmi eğitim, ağırlık paylaşımı veya proxy görevler kullanılabilir.

#### Avantajları

- İnsan uzmanlara kıyasla çok daha geniş bir mimari uzayını keşfedebilir.
- Uygulama özelinde (görüntü sınıflandırma, doğal dil işleme vb.) en uygun ağı mimarisini bulur.
- Derin öğrenme model geliştirme sürecini otomatikleştirir.

## Dezavantajları

- Hesaplama maliyeti oldukça yüksektir.
  - Çok büyük donanım kaynakları gerektirebilir.
  - Araştırma süreci uzun zaman alabilir.
- 
- AutoML, makine öğrenmesindeki tüm süreci kapsayan daha geniş bir alandır.
  - NAS ise AutoML'in bir alt dalıdır ve yalnızca **sinir ağı mimarilerinin otomatik tasarımı** ile ilgilenir.
  - Yani AutoML, "hangi model seçilmeli?" sorusunu sorarken; NAS, "hangi sinir ağı mimarisi en uygundur?" sorusunu yanıtlar.

## Kullanım Alanları

- **Görüntü İşleme:** Nesne tanıma, görüntü sınıflandırma.
- **Doğal Dil İşleme:** Metin sınıflandırma, çeviri, duygu analizi.
- **Ses Tanıma:** Konuşma tanıma ve sesli asistanlar.
- **Sağlık:** Tıbbi görüntülerden otomatik teşhis.

# Yapay Sinir Ağları ile proje örnekleri :

## 1. Çalışan Maaş Tahmini

- **Amaç:** Çalışanların pozisyon, tecrübe yılı, eğitim seviyesi gibi özelliklerine bakarak maaşlarının tahmin edilmesi.
- **Yöntem:** Yapay sinir ağları kullanılarak regresyon analizi yapılır.
- **Kullanım Alanı:** İnsan kaynakları, şirket bütçeleme ve ücretlendirme politikaları.

## 2. Otokoderler (Autoencoders) Kullanan El Yazısı Tanıma Aracı

- **Amaç:** El yazısı rakam veya harflerin tanınması.
- **Yöntem:** Otokoderler ile özellik çıkarımı yapılır, ardından sınıflandırıcı katmanlarla tahmin gerçekleştirilir.
- **Kullanım Alanı:** Eğitim, belge dijitalleştirme, görme engelliler için araçlar.

### 3. RNN Kullanarak Borsa Değer Tahmin Sistemi

- **Amaç:** Hisse senedi veya kripto para fiyatlarının gelecekteki değerlerini tahmin etmek.
- **Yöntem:** Zaman serisi verileri üzerinde Tekrarlayan Sinir Ağları (RNN, LSTM, GRU) kullanılır.
- **Kullanım Alanı:** Finans sektörü, yatırım danışmanlığı, risk yönetimi.

### 4. Müzik Türü Sınıflandırması

- **Amaç:** Bir müzik parçasının rock, pop, klasik, caz gibi türlere ayrılması.
- **Yöntem:** Ses dosyalarından elde edilen özellikler (MFCC, tempo, frekans spektrumu) CNN veya RNN ile sınıflandırılır.
- **Kullanım Alanı:** Müzik öneri sistemleri, dijital müzik platformları.



## 5. Araç Güvenlik Sistemi

- Amaç: Araçlarda kaza önleme veya sürücü dikkat takibi.
- Yöntem: CNN tabanlı nesne tespiti (yaya, trafik levhası, araç algılama) ve RNN tabanlı zaman serisi analizleri.
- Kullanım Alanı: Otonom araçlar, sürücü destek sistemleri.

## 6. Cinsiyet Tanıma Sistemleri

- Amaç: Görüntü veya ses verisinden bireyin cinsiyetini tahmin etmek.
- Yöntem: CNN (görüntü için) veya RNN (ses için) tabanlı sınıflandırma.
- Kullanım Alanı: Güvenlik, kullanıcı deneyimi kişiselleştirme.

## 7. Metin Özetleyici (Text Summarizer)

- **Amaç:** Uzun metinleri otomatik olarak kısa ve anlamlı özetlere dönüştürmek.
- **Yöntem:** Seq2Seq (Encoder–Decoder), LSTM veya Transformer tabanlı modeller.
- **Kullanım Alanı:** Haber özetleme, belge analizi, eğitim teknolojileri.

## 8. Müşteri Kaybı Tahmini (Customer Churn Prediction)

- **Amaç:** Hangi müşterilerin hizmeti bırakacağını tahmin etmek.
- **Yöntem:** Müşteri geçmişi, harcama alışkanlıkları ve kullanım sıklığı gibi verilerle sınıflandırma yapılır.
- **Kullanım Alanı:** Telekom, bankacılık, e-ticaret.

## 9. Dolandırıcılık Tespiti (Fraud Detection)

- **Amaç:** Sahte işlemleri (kredi kartı dolandırıcılığı, sahte ödeme) tespit etmek.
- **Yöntem:** Anormal işlem örüntülerini tespit etmek için sinir ağları ve derin öğrenme.
- **Kullanım Alanı:** Bankacılık, sigorta, çevrim içi alışveriş.